

Razonamiento con Incertidumbre (RAIN)

Diagnóstico bayesiano

PROVISIONAL

Guía para diseñar e implementar vuestro sistema

Erik Figueiral Alonso

erik.figueiral.alonso@uvigo.gal

Guion: de las observaciones al diagnóstico

EL RETO

- | | | |
|-----------|-------------------|---|
| 01 | El reto | Una bomba tiene caudal bajo. ¿Qué puede fallar? |
| 02 | Conceptos | Probabilidades, evidencia y regla de Bayes. |
| 03 | Modelo | Variables, red y tablas de probabilidades. |
| 04 | Inferencia | Actualizar el diagnóstico con nuevas observaciones. |
| 05 | Aplicación | Código, interfaz y comprobaciones. |

El reto: una bomba con caudal bajo

EL RETO

**La bomba funciona,
pero entrega poco caudal.**

Queremos identificar la causa principal:
obstrucción, fuga u otra.

Podemos observar

Caudal bajo

Vibración alta

Las observaciones ayudan a revisar la probabilidad de cada causa.

Probabilidad y pertenencia fuzzy


CONCEPTOS NECESARIOS

Fuzzy	Bayesiano
¿En qué grado encaja «temperatura alta»?	¿Qué probabilidad tiene una avería, dada la evidencia?
$\mu_{\text{alta}}(\text{temperatura}) = 0,8$	$P(\text{avería} \mid \text{observaciones}) = 0,8$

Un grado de pertenencia y una probabilidad tienen significados distintos.

Qué entra y qué sale de la aplicación

CONCEPTOS NECESARIOS



La red y sus tablas constituyen el conocimiento del modelo.

La interfaz recoge evidencias y muestra el resultado de la inferencia.

Tres términos que usaremos

CONCEPTOS NECESARIOS

Hipótesis

Lo que queremos averiguar: la causa principal H.

Evidencia

Lo que hemos observado: la bomba tiene caudal bajo.

Posterior

La probabilidad de cada hipótesis después de observar.

El diagnóstico es una distribución de probabilidades.

Variables y estados del ejemplo

CONCEPTOS NECESARIOS

Variable	Estados	Papel
H: causa principal	Obstrucción / Fuga / Otra	Consulta
Q: caudal bajo	Sí / No	Observable
V: Vibración alta	Sí / No	Observable

«Desconocido» indica falta de observación; no es otro estado de Q o V.

Una distribución reparte la probabilidad

CONCEPTOS NECESARIOS

Causa principal H	Probabilidad inicial
Obstrucción	0,30
Fuga	0,20
Otra causa	0,50
Total	1,00

Son valores ficticios para una población de equipos bajo estudio.

La dirección de la pregunta importa

CONCEPTOS NECESARIOS

$$P(\text{caudal bajo} \mid \text{obstrucción}) = 0,90$$

Si la causa es la obstrucción, ¿con qué frecuencia hay caudal bajo?

$$P(\text{obstrucción} \mid \text{caudal bajo}) = ?$$

Si el caudal es bajo, ¿qué probabilidad hay de obstrucción?

La regla de Bayes

CONCEPTOS NECESARIOS

$$P(H | E) = P(E | H) \cdot P(H) / P(E)$$

$P(H)$: punto de partida

La probabilidad antes de incorporar esta evidencia.

$P(E | H)$: compatibilidad con la observación

Cuánto cabe esperar esa evidencia si H es cierta.

Dividimos por $P(E)$ para que las probabilidades posteriores sumen 1.

La red completa: grafo y probabilidades

MODELO DE DIAGNÓSTICO

Nodo sin padres

Su tabla contiene probabilidades iniciales.

Valores ficticios.

H: causa principal

H	P(H)
Obstrucción	0,30
Fuga	0,20
Otra	0,50

Nodo con padre H

Su tabla contiene probabilidades condicionadas a H.

Q: caudal bajo. Tabla P(Q | H)

Causa H	Q = sí	Q = no
Obstrucción	0,90	0,10
Fuga	0,80	0,20
Otra	0,10	0,90


V: vibración alta. Tabla P(V | H)

Causa H	V = sí	V = no
Obstrucción	0,80	0,20
Fuga	0,20	0,80
Otra	0,10	0,90

Los números pertenecen a las tablas de los nodos. Las flechas indican sus dependencias.

La simplificación que permite multiplicar

MODELO DE DIAGNÓSTICO



Suponemos que, conocida H, observar Q no aporta información adicional sobre V.

$$P(Q, V | H) = P(Q | H) \cdot P(V | H)$$

Naive Bayes supone independencia de los síntomas dada la causa. Debemos justificarla.

Cómo leer los números de la red

MODELO DE DIAGNÓSTICO

$$P(H = \text{obstrucción}) = 0,30$$

Antes de observar los síntomas, asignamos un 30 % a esta causa.

$$P(Q = \text{sí} \mid H = \text{obstrucción}) = 0,90$$

Si la causa es una obstrucción, el modelo asigna un 90 % a que haya caudal bajo.

La probabilidad de obstrucción después de observar caudal bajo requiere inferencia.

Primera observación: la bomba tiene caudal bajo

INFERENCIA PASO A PASO

Evidencia: $Q = \text{sí}$. Todavía no hemos observado la vibración.

Hipótesis	$P(H)$	$P(Q = \text{sí} \mid H)$	Peso conjunto
Obstrucción	0,30	0,90	0,270
Fuga	0,20	0,80	0,160
Otra	0,50	0,10	0,050

Peso = prior × verosimilitud. Aún falta normalizar.

Podemos verlo como 1.000 casos hipotéticos

INFERENCIA PASO A PASO

Causa	Casos iniciales	Con caudal bajo
Obstrucción	300	$300 \times 0,90 = 270$
Fuga	200	$200 \times 0,80 = 160$
Otra	500	$500 \times 0,10 = 50$
Total	1.000	480

De los 480 casos que tienen caudal bajo, 270 corresponden a obstrucción.

Normalizar produce el primer diagnóstico

INFERENCIA PASO A PASO

$$P(Q = \text{sí}) = 0,270 + 0,160 + 0,050 = 0,480$$

Hipótesis	Cálculo	Posterior
Obstrucción	$0,270 / 0,480$	56,25 %
Fuga	$0,160 / 0,480$	33,33 %
Otra	$0,050 / 0,480$	10,42 %

Obstrucción es la hipótesis más probable, pero siguen existiendo alternativas.

La red con evidencia: caudal bajo y vibración alta

INFERENCIA PASO A PASO

La inferencia revisa H a partir de Q y V.

Posterior de H

Causa	Probabilidad
Obstrucción	85,38 %
Fuga	12,65 %
Otra	1,98 %

Las tablas del modelo se mantienen.
Cambia la posterior.

Q observado: caudal bajo = sí

V observado: vibración alta = sí

Estos porcentajes son resultados de la consulta, no nuevas probabilidades de las tablas.

Dos observaciones: combinar y normalizar

INFERENCIA PASO A PASO


Hipótesis	$P(H) \times P(Q H) \times P(V H)$	Peso
Obstrucción	$0,30 \times 0,90 \times 0,80$	0,216
Fuga	$0,20 \times 0,80 \times 0,20$	0,032
Otra	$0,50 \times 0,10 \times 0,10$	0,005

Total = 0,253 $P(\text{obstrucción} | Q, V) = 0,216 / 0,253$

Resultado: obstrucción 85,38 %, fuga 12,65 %, otra 1,98 %.

Cómo cambia el diagnóstico

INFERENCIA PASO A PASO



El modelo se mantiene. Cambia la evidencia y cambia la posterior.

«No observado» y «no» producen resultados distintos

INFERENCIA PASO A PASO

Con Q = sí	Tratamiento de la vibración	P(obstrucción evidencia)
Vibración desconocida	No añadimos V a la evidencia	56,25 %
Vibración alta	V = sí	85,38 %
Vibración normal	V = no	23,79 %

La interfaz necesita distinguir Sí, No y No observado.

Qué hacemos con una observación desconocida

INFERENCIA PASO A PASO

No hemos observado V. Consideramos sus dos posibilidades.

$$P(H, Q) = P(H, Q, V = \text{sí}) + P(H, Q, V = \text{no})$$

Para obstrucción: $0,216 + 0,054 = 0,270$

Sumar sobre los estados de una variable se llama marginalizar.

Qué hace un motor de inferencia

INFERENCIA PASO A PASO

Fija las observaciones

Selecciona los estados que sí conocemos.

Combina y suma

Usa las tablas y marginaliza las variables no observadas.

Normaliza la consulta

Devuelve una distribución sobre las hipótesis.

La eliminación de variables realiza este cálculo evitando repetir operaciones.

Diseñar vuestro modelo antes de programarlo

DISEÑO E IMPLEMENTACIÓN

Objetivo

Qué queréis diagnosticar y en qué contexto se usará.

Observaciones

Qué puede introducir o medir realmente el usuario.

Conocimiento


Qué dependencias y probabilidades podéis justificar.

El tamaño de la red debe responder al problema, no al deseo de añadir nodos.

Si las causas pueden coexistir, cambia la red

DISEÑO E IMPLEMENTACIÓN

Dos variables binarias permiten representar ambas causas a la vez.



La tabla del caudal debe cubrir las cuatro combinaciones de sus dos padres.

De dónde salen las probabilidades

DISEÑO E IMPLEMENTACIÓN

Datos

Estimar frecuencias condicionadas en casos representativos.

Conocimiento experto

Preguntar por situaciones concretas y registrar los supuestos.

Revisión

Contrastar con casos nuevos y comprobar la sensibilidad.

Las cifras de este ejemplo son supuestos docentes y no deben presentarse como datos.

Código: las probabilidades del ejemplo

DISEÑO E IMPLEMENTACIÓN

```
PRIOR = {"obstruccion": 0.30, "fuga": 0.20, "otra": 0.50}
```

```
PROB_SI = {  
    "caudal_bajo": {  
        "obstruccion": 0.90, "fuga": 0.80, "otra": 0.10  
    },  
    "vibracion_alta": {  
        "obstruccion": 0.80, "fuga": 0.20, "otra": 0.10  
    }  
}
```

Cada valor es $P(\text{observación} = \text{sí} \mid \text{causa})$. El «no» se obtiene por complemento.

Código: el cálculo para esta red

DISEÑO E IMPLEMENTACIÓN

```
def diagnosticar(evidencia):
    pesos = PRIOR.copy()
    for variable, observado in evidencia.items():
        for h in pesos:
            p_si = PROB_SI[variable][h]
            pesos[h] *= p_si if observado else 1 - p_si
    total = sum(pesos.values())
    if total <= 0:
        raise ValueError("Evidencia imposible")
    return {h: peso / total for h, peso in pesos.items()}
```

Exacto para nuestro modelo naive Bayes. No es un motor para cualquier red.

Código: consultar con y sin observaciones

DISEÑO E IMPLEMENTACIÓN

```
diagnosticar({})  
# obstruccion: 0.30, fuga: 0.20, otra: 0.50
```

```
diagnosticar({"caudal_bajo": True})  
# obstruccion: 0.5625, fuga: 0.3333, otra: 0.1042
```

```
diagnosticar({"caudal_bajo": True, "vibracion_alta": True})  
# obstruccion: 0.8538, fuga: 0.1265, otra: 0.0198
```

Una variable no observada se omite del diccionario.

Una biblioteca para redes más generales

DISEÑO E IMPLEMENTACIÓN

Modelo

DiscreteBayesianNetwork define el grafo. TabularCPD define sus tablas.

Comprobación

check_model() verifica coherencia estructural de las tablas.

```
motor = VariableElimination(modelo)
q = motor.query(
    variables=["H"], evidence={"Q": "si", "V": "si"}
)
```

Ejemplo de API de pgmpy. Las tablas y nombres de estado deben estar definidos.

La interfaz conserva el significado de la evidencia

DISEÑO E IMPLEMENTACIÓN


Pregunta	Opciones de entrada
¿El caudal es bajo?	Sí / No / No observado
¿La vibración es alta?	Sí / No / No observado

Salida: probabilidades de todas las causas y observaciones utilizadas.

Al cambiar una respuesta, recalculamos con el conjunto actual de observaciones.

MVC: los eventos activan el diagnóstico

DISEÑO E IMPLEMENTACIÓN



1. El controlador registra el manejador del evento.
2. Valida la entrada y solicita la inferencia al modelo.
3. Recibe la posterior y pide a la vista que la muestre.

El modelo encapsula el conocimiento y el cálculo probabilístico.

Comprobaciones con resultados conocidos

DISEÑO E IMPLEMENTACIÓN

Evidencia	Obstrucción	Fuga	Otra
Ninguna	30,00 %	20,00 %	50,00 %
Caudal bajo	56,25 %	33,33 %	10,42 %
Caudal bajo + Vibración alta	85,38 %	12,65 %	1,98 %
Caudal bajo + Vibración normal	23,79 %	56,39 %	19,82 %

Comprobado también reinicio, entradas inválidas y suma de probabilidades igual a 1.

Que el código funcione no valida el modelo

DISEÑO E IMPLEMENTACIÓN

Casos de prueba

Comprobar diagnósticos con causas conocidas y casos difíciles.

Probabilidades

Revisar si la confianza de las predicciones concuerda con los resultados.

Sensibilidad

Variar supuestos dudosos y observar si cambia la conclusión.

Conservar los casos de evaluación separados de los usados para ajustar.

La causa más probable no decide la acción

DISEÑO E IMPLEMENTACIÓN

Obstrucción: 85,38 %

¿Desmontamos directamente la tubería?

¿O hacemos antes una comprobación barata?

Elegir una acción también requiere valorar el coste y las consecuencias de equivocarse.

El sistema apoya el diagnóstico. La acción requiere criterios adicionales.

Ejercicio: aparece una observación diferente

DISEÑO E IMPLEMENTACIÓN

La bomba tiene caudal bajo, pero la vibración es normal.

1. ¿Qué valores tiene la evidencia Q, V?
2. Calculad los tres pesos usando la tabla.
3. Normalizad y decidid qué causa resulta más probable.

Usad $P(V = \text{no} \mid H) = 1 - P(V = \text{sí} \mid H)$.

Solución: la nueva evidencia cambia la prioridad

DISEÑO E IMPLEMENTACIÓN

Hipótesis	Peso con Q = sí, V = no	Posterior
Obstrucción	$0,30 \times 0,90 \times 0,20 = 0,054$	23,79 %
Fuga	$0,20 \times 0,80 \times 0,80 = 0,128$	56,39 %
Otra	$0,50 \times 0,10 \times 0,90 = 0,045$	19,82 %

Total = 0,227. Ahora la hipótesis más probable es fuga.

«Vibración normal» y «Vibración desconocida» no son la misma evidencia.

Qué debería quedar en vuestro diseño

DISEÑO E IMPLEMENTACIÓN

Modelo explícito

Variables, estados, grafo, tablas y fuentes o supuestos.

Aplicación local con interfaz

Introducción de evidencias, inferencia y presentación del diagnóstico.

Comprobaciones

Casos de prueba y límites de lo que el sistema puede concluir.

Libertad de implementación. Lo esencial es justificar cómo se obtiene el diagnóstico.

Referencias y continuación de la lectura

DISEÑO E IMPLEMENTACIÓN

Luis Enrique Sucar

Probabilistic Graphical Models: Principles and Applications
2.^a edición, Springer, 2021

Para esta práctica: capítulo 2 y, especialmente, capítulo 7.
Capítulo 4 para naive Bayes. Capítulo 8 si vais a aprender con datos.

Materiales públicos del autor y documentación de pgmpy:
enlaces completos en las notas de las diapositivas.